

# Proyecto Final de Sistemas de Información

Carlos Jorge Rodríguez Cuello C-511

Ricardo Iván Valdez Rodríguez C-511

Roberto Zahuís Benítez C-511

January 7, 2020

## 1 Resumen

Con el desarrollo de las redes sociales las noticias falsas por motivos comerciales y políticos han estado apareciendo en grandes cantidades en el mundo de internet. Las personas pueden ser influenciadas por estas noticias fácilmente, posibilitando que estas se compartan sin verificar su veracidad.

La detección automática de las noticias falsas es extremadamente difícil, un modelo basado en comprobación rápida de una noticia es un problema abierto y algunos pocos modelos pueden ser aplicados para resolver el problema.

En este proyecto se propone un modelo que solo usa la información del texto de las noticias para detectar si estas son falsas o no.

## 2 Introducción

Las noticias falsas se tienen registro desde el siglo XIX. En 1835, New York Sun publica una serie de artículos acerca del descubrimiento de vida en la luna. Pronto las historias falsas fueron impresas en periódicos de Europa. En la actualidad éstas presentan un gran problema en el mundo de internet. Las personas de hoy no sólo expuestas a la cultura de comida rápida pueden creer en algo fácilmente sin verificar su veracidad. La difuminación de noticias falsas es un fenómeno que es muy común en las redes sociales, las cuales son de diferente índole (políticas, celebridades, promociones de productos, etc). Acorde a los resultados estadísticos reportado por investigadores de la Universidad de Stanford, el 72.3% de las noticias falsas actuales tienen sus orígenes de los medios fuentes oficiales y de las redes sociales.

La identificación de noticias falsas en las redes sociales es un gran reto por

dos razones. Primeramente la dificultad de recolectar las noticias y sumado a eso es difícil etiquetarlas manualmente. Segundo, las noticias falsas son escritas por humanos. La mayoría de mentiras se elaboran usando algunas estrategias del lenguaje para evitar ser capturadas.

En este trabajo se cuenta con una colección de los textos 20000 noticias, 10000 verdaderas y 10000 falsas, de variados sitios, donde en el resto de los puntos que se abordarán se profundiza la definición del problema, que propuesta de solución se llevo a cabo y los resultados obtenidos.

### **3 Estado de Arte**

La detección de engaños ha sido un tema muy debatido los último años. La información engañosa puede ser fraudes científicos, noticias falsas, falsos tweets, etc. Para revolver los problemas de detección de engaños se tienen en cuenta dos aspectos: 1 acercamiento lingüístico 2 acercamiento con las redes.

#### **3.1 Acercamiento lingüístico**

Mihalcea and Strapparvva 2009 empiezan usando técnicas de procesamiento del lenguaje natural (NLP por sus siglas en inglés) para resolver el problema. Bing Liu et.al. analizó las críticas falsas de Amazon basándose en el análisis de sentimientos, léxico, similaridad del contenido, similaridad de estilos e inconsistencia semántica. Hai et al. [3] propone un algoritmo de aprendizaje semi-supervisado para detectar texto engañoso en 2016. Estos métodos basado en el análisis de las palabras no son suficiente para identificar los engaños. Muchos investigadores se han enfocado en algunas estructuras del lenguaje (por ejemplo: Las oraciones son representadas como un árbol de parser que define una estructura sintáctica)

#### **3.2 Acercamiento basado en redes**

Otra manera para identificar los engaños es analizando la estructura de redes, los investigadores las conocen como grafos siendo utilizados para establecer relaciones entre las entidades. Ciampaglia et al. [4] propone un nuevo concepto llamado variables “network effect” que se derivan de las propabilidades de las noticias. Los métodos basados en el análisis de grafos pueden lograr una presición de 61% a 95%.

### 3.3 Acercamiento basado en redes neuronales

Los modelos de deep learning [2] son altamente utilizados tanto en la comunidad académica como la industria. En visión por computadora y reconocimiento del habla, el estado del arte es en su mayoría redes neuronales profundas. En el área del procesamiento del lenguaje natural, los modelos de deep learning son usados para entrenar modelos que pueden representar palabras como vectores. Las investigaciones proponen muchos modelos de deep learning basados en vectores de palabras como QA [5] y resumen [6], etc. Las redes neuronales convolucionales (CNN por sus siglas e inglés) utilizan filtros para detectar patrones locales en las imágenes, las cuales se desempeña muy bien en tareas de visión por computadora. Muchas investigaciones muestran a las CNN efectivas en muchas tareas de NLP como parseo semántico, modelado de oraciones, etc.

## 4 Propuesta de solución

### 4.1 Formalización del problema

Dado un conjunto de  $m$  artículos que contienen solo texto, se puede representar el conjunto de datos como  $\mathcal{A} = \{A_i^T\}_i^m$ . En el problema de noticias falsa se busca predecir si los artículos de noticias en  $\mathcal{A}$  son falsos o no. Se puede representar el conjunto de etiquetas como  $\mathcal{Y} = \{0, 1\}$ , donde 0 denota las noticias falsas y 1 las noticias reales. El objetivo del problema. Basado en las noticias  $A_i^T \in \mathcal{A}$  se puede extraer la información del texto  $X_i^T$ . Por lo tanto el objetivo del problema de detección de noticias falsas es construir un modelo  $f : \{X_i^T\}_i^m \in X \rightarrow \mathcal{Y}$  para predecir las etiquetas potenciales de las noticias de  $\mathcal{A}$  [1].

## **4.2 Análisis del texto**

Primeramente se hizo un análisis de determinadas características de las noticias falsas para incorporar esta información al texto.

### **4.2.1 Número de palabras y oraciones**

Las noticias falsas en promedio tienen menos palabras, que las reales. Además, el número de palabras en una noticia falsa distribuye sobre una gran variedad, lo que indica que algunas noticias falsas tienen muy pocas palabras y algunas tienen un montón de palabras. Además, el tamaño de las oraciones de las noticias reales es más corto que el de las noticias falsas, también la variancia de las noticias reales es más corta que la de las noticias falsas en cuanto al tamaño de las oraciones. La razón es que el editor de una noticia real debe escribir el artículo bajo ciertas reglas de la prensa.

### **4.2.2 Signo de interrogación, exclamación**

Las noticias reales tienen menos signos de interrogación que las noticias falsas. Las razones pueden consistir en que hay muchas preguntas retóricas en las noticias falsas. Estas preguntas retóricas se usan siempre para enfatizar las ideas conscientemente e intensificar el sentimiento. Según el análisis en los datos, nos damos cuenta de que ambas noticias reales y falsas tienen muy pocas exclamaciones, sin embargo las falsas están de parte de usar las palabras con exclamaciones para abanicar emociones específicas entre los lectores.

### **4.2.3 Número de negaciones**

Las negaciones (no,not) son usadas en las reales con más frecuencia. La media de las negaciones en las noticias falsas es mucho más pequeña que en las reales. El engañador debe ser más específico y meticuloso cuando usan negaciones y palabras exclusivas, para aminorar la probabilidad de ser percibido en una contradicción.

### **4.2.4 Número de pronombres en primera persona**

Desde esta perspectiva, nosotros vamos a investigar el uso de pronombres de primera persona (I,me,we). Las personas engañosas a menudo usan lenguaje que se minimiza referencias para ellos mismos y a usar otros pronombres personales. Nos encontramos con que la información engañosa puede ser

caracterizada por el uso de menos primera persona, menos segunda persona y más pronombres de terceras personas.

#### 4.2.5 Diversidad léxica

Esta es medida con cuantas palabras diferentes son usadas en un texto, mientras la densidad léxica provee una manera de medir de elementos léxicos (sustantivo, verbos, adjetivos y algunos adverbios). Una noticia enriquecedora tiene más diversidad. Según los resultados experimentales, la diversidad léxica de una noticia real es 2.2e-06, que es más grande que 1.76e-06 para la noticia de un solo día.

### 4.3 Modelo

Para este modelo utilizaremos CNNs para la información latente del texto.

#### 4.3.1 Características explícitas del texto $X^{Te}$

Esta es derivada de las estadísticas de los textos mencionadas en el análisis del texto (tamaño del texto, cantidad de oraciones, signos de interrogación, de exclamación, etc ). Estas son ser organizadas en un vector de tamaño fijo.

#### 4.3.2 Características latentes del texto $X^{Te}$

Estas se basan en una variante de CNN [2] (CNN muestra un notable rendimiento en tareas de Procesamiento del lenguaje natural). Con la convolución, la red neuronal puede producir rasgos locales alrededor de cada palabra, estos se combinan usando una operacin max. Gracias a la capa de embendding se procesa la  $j - esima$  palabra de la noticia  $i$  como  $x_{i,j} \in \mathbb{R}^k$ .

Supongamos el mximo tamaño de una noticia es  $n$ . Las noticias que tengan menor tamaño que  $n$  pueden ser representadas por un tamaño  $n$ . Entonces:

$$X_{i,1:n}^{Tl} = x_{i,1} \oplus x_{i,2} \oplus \dots \oplus x_{i,n} \quad (1)$$

Es decir  $X_{i,1:n}^{Tl}$  es la concatenación de cada vector que representan sus palabras. Usando filtros convolucionales  $w \in \mathbb{R}^{h \times k}$  para construir nuevas características. Para una instancia una ventana de palabras  $X_{i,j:j+h-1}^{Tl}$  puede producirse una característica  $c_i$  de la siguiente manera:

$$c_i = f(w \cdot X_{i,j:j+h-1}^{Tl} + b) \quad (2)$$

donde  $b$  es el bias,  $f$  es una transformación no lineal(ReLU, sigmoide,etc). Aplicando filtros en cada ventana se tiene un tensor de la siguiente manera:

$$c = [c_1, c_2, \dots, c_{n-h+1}] \quad (3)$$

Donde  $c \in \mathbb{R}^{n-h+1}$ . Una capa max-pooling es aplicada para tomar el máximo valor es denotada como  $\hat{c} = \max\{c\}$ . La capa max-pooling puede mejorar la robustez de un modelo reservando los resultados convolucionales más importantes para detectar las noticias falsas.

### 4.3.3 Arquitectura del modelo

Table 1: BN: BATCH NORMALIZATION, RELU: RECTIFIED LINEAR ACTIVATION FUNCTION, CONV1D: CONVOLUTIONAL LAYER ON 1D DATA, DENSE: DENSE LAYER, EMB: EMBEDDING LAYER MAXPO1D: MAX-POOLING ON 1D DATA.

Características explícitas del texto	Características latentes del texto
Input $7 \times 1$	Emb(100,100) Dropout(0.5)
DENSE(8)	CONV1D(10, 7) MAXPO1D(2) CONV1D(10, 7) GlobalPooling1D
BN	DENSE(8) BN ReLU
Merge	
DENSE(8)	
BN	
Sigmoid	

## 5 Resultados

Después de entrenar con un dataset de 20000 noticias, se tuvo muy buenos resultados dando un score de 0.9762 y una perdida de solamente 0.069 y otra métrica que se usó fué el f1 score q dió otro gran resultado ya que tuvo un valor muy cerca de 1(0.9776 para ser exacto).




Figure 1:




Figure 2:




Figure 3:

## 6 Conclusiones

La difusión de noticias falsas han generado preocupaciones en todo el mundo recientemente. Estas noticias pueden tener graves consecuencias. La identificación de las noticias falsas crece en importancia. Se propone combinar la información de las correspondientes características explícitas y latentes. El modelo tiene una gran capacidad de expansión, puede abosorber fácilmente otras características de las noticias. Además la red neuronal convolucional hace que el modelo vea toda la entrada a la vez, y pueda ser entrenado mucho más rápido que LSTM y muchos otros modelos RNN. Dado nuestro DataSet se muestra que nuestro modelo puede identificar con éxito las noticias falsas basadas en las características explícitas y latentes aprendidas de las redes convolucionales.

## References

- [1] *TI-CNN: Convolutional Neural Networks for Fake News Detection*, Jun 2018
- [2] *François Chollet, Deep Learning with Python, 2018.*
- [3] *Zhen Hai, Peilin Zhao, Peng Cheng, Peng Yang, Xiao-Li Li, Guangxia Li, and Ant Financial. Deceptive review spam detection via exploiting task relatedness and unlabeled data. EMNLP, 2016.*
- [4] *Giovanni Luca Ciampaglia, Prashant Shiralkar, Luis M Rocha, Johan Bollen, Filippo Menczer, and Alessandro Flammini. Computational fact checking from knowledge networks. PloS one, 10(6):e0128193, 2015.*



- [5] *Kan Chen, Jiang Wang, Liang-Chieh Chen, Haoyuan Gao, Wei Xu, and Ram Nevatia. Abc-cnn: An attention based convolutional neural network for visual question answering. arXiv preprint arXiv:1511.05960, 2015.*
- [6] *Khosrow Kaikhah. Automatic text summarization with neural networks. In Intelligent Systems, 2004. Proceedings. 2004 2nd International IEEE Conference, volume 1, pages 4044. IEEE, 2004.*